

UNIVERSIDAD DEL VALLE DE GUATEMALA

Colegio Universitario



Laboratorio No. 4 – Parte 2

Catedrático: Lynette Garcia

Jose Ordoñez – 231329

Adrián Gonzáles – 23152

José Antón - 221041

Data Science

Sección 10

Guatemala, 2026

10. Análisis y conclusiones

10.1 Capacidad del modelo como herramienta de apoyo

Sí consideramos que el modelo desarrollado tiene suficiente capacidad para utilizarse como herramienta de apoyo en el monitoreo de cianobacteria, aunque no como sustituto del muestreo de campo. Los experimentos realizados respaldan esta posición. Los modelos de ensamble superaron ampliamente al modelo lineal de referencia: XGBoost alcanzó un F1 de 0.636 y un ROC-AUC de 0.865 (Random Forest: F1 = 0.637, AUC = 0.862), frente a un F1 de 0.475 y un AUC de 0.699 de la regresión logística, lo que confirma que la relación entre las variables espectrales y espaciales y la presencia de floraciones es no lineal, pero sí predecible.

El desempeño además se sostiene bajo validación cruzada espacial con bloques de 1 km (F1 $\approx$ 0.62), lo que indica que el modelo aprende patrones geográficos reales y no únicamente la autocorrelación entre píxeles vecinos. El recall alto de XGBoost ($\approx$ 0.78–0.79) es especialmente valioso en este contexto: dado que un falso negativo (no alertar sobre una zona con floración) tiene consecuencias ambientales y de salud pública mucho mayores que un falso positivo, un modelo orientado a maximizar la detección es el apropiado para un sistema de alerta temprana. Asimismo, los mapas predictivos reproducen el patrón espacial observado —riesgo crónico y extendido en Amatitlán, focos localizados en Atilán— y las variables más influyentes según SHAP (NDVI, NDWI) coinciden con los hallazgos de la Parte I.

En síntesis, el modelo es útil para priorizar zonas de muestreo y emitir alertas preventivas a partir de imágenes satelitales de acceso gratuito, complementando —sin reemplazar— las mediciones in situ.

10.2 Principales limitaciones

Calidad de la etiqueta: la variable respuesta se deriva de un índice satelital (NDCI $\rightarrow$ Chl-a) sin calibración con mediciones de campo, y su umbral es relativo (percentil 75 por lago), por lo que describe anomalías relativas y no concentraciones absolutas.

Cobertura temporal: solo 11 fechas por lago en aproximadamente 18 meses, insuficientes para capturar toda la estacionalidad y la variabilidad interanual.

Nubosidad y atmósfera: las nubes descartan píxeles o fechas completas (Amatitlán 2026-02-07 conservó casi la mitad de sus observaciones) y pueden dejar brillo residual contaminando las reflectancias.

Resolución y estructura espacial: el submuestreo (stride 5) y la fuerte correlación entre píxeles vecinos reducen la información independiente disponible; el contorno del lago se aproximó con la máscara NDWI al no contar con polígonos oficiales.

Diferencias entre lagos: la generalización cruzada cae fuertemente: en Atitlán→Amatitlán la regresión logística obtuvo recall ≈ 0.02 y en el sentido inverso la exactitud se desplomó a 0.32, evidenciando niveles de fondo y dinámicas distintas en cada lago.

Metodología de validación: la división aleatoria 70/30 sobreestima el desempeño por autocorrelación espacial; la validación agrupada por bloques es más honesta, y los mapas predictivos emplean predicciones dentro de la muestra, por lo que subestiman el error real.

10.3 Información adicional que podría mejorar el modelo

Muestreos físicos: mediciones concurrentes con las pasadas satelitales (clorofila-a, ficocianina, cianotoxinas) para calibrar el índice NDCI y construir etiquetas observadas.

Variables meteorológicas: temperatura del aire y del agua, viento, radiación y precipitación, ya que las floraciones responden a calor y estratificación.

Variables hidrológicas: caudales y descargas de aguas residuales, nivel del lago y arrastre de nutrientes desde la cuenca (nitratos, fosfatos).

Mayor densidad temporal: series más largas y con todas las imágenes despejadas disponibles, para capturar estacionalidad e interanualidad.

Información geoespacial oficial: polígonos de los lagos, batimetría y usos de suelo de la cuenca, para mejorar las máscaras de agua y las características espaciales.