

UNIVERSIDAD DEL VALLE DE GUATEMALA
Colegio Universitario



Laboratorio 5

Catedrático: Lynette García

Integrantes

José Ordoñez — 231329
Adrián González — 23152
José Antón — 221041

CC3084 — Data Science
Universidad del Valle de Guatemala — Semestre II, 2026

1. Introducción

Este informe documenta el desarrollo del Laboratorio 5 del curso de Data Science (CC3084), cuyo objetivo es aplicar técnicas de procesamiento de lenguaje natural (NLP) sobre un conjunto de tweets para determinar cuáles describen un desastre real y cuáles no. El conjunto de datos (train.csv) contiene 7,613 tweets etiquetados con la variable target (1 = desastre real, 0 = no desastre), junto con las columnas keyword, location y text.

El trabajo se organiza en las siguientes etapas: limpieza y preprocesamiento del texto, análisis exploratorio de frecuencias y n-gramas, entrenamiento y comparación de varios modelos de clasificación supervisada, construcción de una función para clasificar tweets nuevos, análisis de sentimiento basado en léxico, identificación de los tweets más extremos en sentimiento, y evaluación del efecto de agregar una variable de "negatividad" al modelo de clasificación.

Todo el código se implementó en Python utilizando pandas, scikit-learn, NLTK y WordCloud; el detalle completo de la implementación se encuentra en el notebook Laboratorio5.ipynb del repositorio del curso.

2. Limpieza y preprocesamiento del texto

Antes de cualquier análisis se aplicó una función de limpieza (clean_text) a la columna text, generando la columna text_limpio. Los pasos aplicados y su justificación se resumen en la Tabla 1.

Paso	Justificación
Minúsculas	Unifica variantes de la misma palabra (p. ej. 'Fire' / 'fire') y evita tokens duplicados.
Conservar '911' → 'nineoneone'	Es una señal clave de emergencia; se preserva como token antes de eliminar dígitos.
Eliminar URLs	No aportan información textual sobre el desastre y añaden ruido.
Eliminar números	Cifras espurias (años, cantidades) no distinguen desastres de no desastres.
Eliminar caracteres no alfabéticos	Símbolos, puntuación y emoticonos no aportan al vocabulario del clasificador de texto.
Eliminar stopwords (inglés)	Artículos, preposiciones y conjunciones no discriminan entre clases y sólo agregan dimensiones irrelevantes al vocabulario.

Tabla 1. Pasos de limpieza aplicados a los tweets y su justificación.

Sobre la pregunta de si vale la pena conservar los emoticonos: para el modelo de clasificación de desastre vs. no desastre se decidió eliminarlos, ya que aparecen en muy pocos tweets del dataset y no ayudan a distinguir un incidente real de contenido cotidiano. Sin embargo, como se discute en la Sección 6, para el análisis de sentimiento (Inciso 8) sí se decidió conservarlos y contarlos aparte, porque ahí sí aportan una señal directa de polaridad emocional (p. ej. ":" o "<3").

3. Frecuencia de palabras por categoría

Se calculó la frecuencia de palabras de text_limpio por separado para tweets de desastre (target=1) y de no desastre (target=0). La Tabla 2 muestra las 10 palabras más frecuentes de cada categoría (excluyendo residuos de un solo carácter para mayor claridad interpretativa).

#	Desastre (target=1)	Frecuencia	No desastre (target=0)	Frecuencia
1	news	151	like	254
2	disaster	121	just	234
3	california	115	new	171
4	suicide	112	don	140
5	police	109	body	116
6	people	105	video	96
7	killed	95	people	95
8	hiroshima	94	love	91
9	just	89	time	88
10	storm	89	day	86

Tabla 2. Top 10 palabras más frecuentes por categoría (unigramas, sin contar tokens de una sola letra).




Figura 1. Top 15 palabras más frecuentes por categoría (incluye residuos de tokenización de una letra, p. ej. 's', 't', 'm').

En los tweets de desastre predominan palabras claramente temáticas y con alto poder discriminante: disaster, california, suicide, killed, hiroshima, storm, police. Estas palabras casi no aparecen en los tweets "normales" y por lo tanto son las que más ayudarían a un clasificador a separar ambas clases. En los tweets que no son de desastre predominan palabras genéricas de uso cotidiano: love, day, know, time, video, body (usualmente en contextos figurados, como "body bag" usado coloquialmente y no en sentido literal). También se observan tokens ruidosos como s, t, m, don, amp, residuos de la separación de contracciones (it's → it s) y de entidades HTML (–).

3.1 Bigramas y trigramas

Para capturar contexto que las palabras sueltas no reflejan, se calcularon también los bigramas y trigramas más frecuentes por categoría (Tabla 3).

N-grama	Desastre — top 5	No desastre — top 5
Bigramas	suicide bomber (59); northern california (41); oil spill (38); burning buildings (37); suicide bombing (35)	cross body (39); youtube video (36); liked youtube (35); gt gt (29); body bag (27)
Trigramas	suicide bomber detonated (30); northern california wildfire (29); latest homes razed (28); homes razed northern (28); pkk suicide bomber (28)	liked youtube video (35); reddit quarantine offensive (21); quarantine offensive content (20); cross body bag (19); pick fan army (17)

Tabla 3. Top 5 bigramas y trigramas más frecuentes por categoría.

Los bigramas y trigramas confirman que vale la pena explorarlos: en desastre aparecen combinaciones muy específicas y con sentido literal (suicide bomber, northern california wildfire, oil spill, homes razed), mientras que en no-desastre aparecen combinaciones

que reutilizan las mismas palabras sueltas pero en sentido figurado o distinto. El caso de *burning buildings* es ilustrativo: aparece en ambas categorías con frecuencias similares a nivel de unigrama, lo que muestra que por sí sola esa palabra es ambigua, pero el *n*-grama completo ayuda a distinguir el contexto real (incendio real vs. uso coloquial/metafórico). Esto respalda incluir bigramas como *features* adicionales en el modelo, más allá de unigramas (ver Sección 5).

4. Análisis exploratorio de los datos

4.1 Palabra más repetida por categoría

En ambas categorías el token más frecuente en sentido estricto es 's' (408 en desastre, 608 en no desastre), residuo de la separación de contracciones como it's. Si se excluyen tokens de una sola letra, la palabra más repetida en tweets de desastre es news, y en tweets que no son de desastre es like. Esto refuerza la conveniencia de filtrar tokens de longitud 1 antes de un análisis más fino.

4.2 Nube de palabras por categoría



Figura 2. Nube de palabras — tweets de desastre (izquierda) vs. tweets que no son de desastre (derecha).

4.3 Palabras con presencia en ambas categorías

Comparando el top 50 de palabras más frecuentes de cada categoría, se identificaron 14 palabras compartidas: amp, burning, don, emergency, just, like, m, new, news, people, s, t, u, video.

Entre ellas, s, t, m, amp, don, u son ruido de preprocesamiento (contracciones separadas, entidades HTML, abreviaciones) y no aportan valor discriminante; son buenas candidatas a remover en una limpieza adicional o a agregar a la lista de stopwords. Palabras como people, like, just, new son de uso muy general en inglés cotidiano y, aunque aparecen en ambas clases, su frecuencia relativa dentro de cada clase sí puede

diferir, por lo que no conviene eliminarlas sin analizar antes su importancia (por ejemplo mediante TF-IDF, que sí las pondera de forma diferenciada).

5. Modelos de clasificación

5.1 Representación del texto

Para capturar el contexto observado en la Sección 3 (donde una palabra como "suicide" cambia de sentido según si aparece junto a "bomber" o junto a "note"), se vectorizó `text_limpio` con TF-IDF usando unigramas y bigramas (`ngram_range=(1,2)`), filtrando términos muy raros con `min_df=3` y muy comunes con `max_df=0.9`. Esto produjo un vocabulario de 4,564 términos. Los datos se dividieron 70/30 en entrenamiento y prueba (5,329 / 2,284 tweets), estratificados por target para preservar la proporción de clases ($\approx 43\%$ desastre en ambos subconjuntos).

5.2 Comparación de modelos

Se entrenaron cuatro algoritmos de clasificación binaria sobre la misma representación TF-IDF: Naive Bayes multinomial, Regresión Logística (`class_weight='balanced'`), SVM lineal y Random Forest. La Tabla 4 resume las métricas obtenidas sobre el conjunto de prueba.

Modelo	Accuracy	Precisión	Recall	F1	AUC-ROC
Naive Bayes	0.814	0.853	0.686	0.760	0.862
Regresión Logística	0.800	0.773	0.755	0.764	0.862
SVM Lineal	0.781	0.744	0.747	0.746	0.843
Random Forest	0.791	0.795	0.691	0.739	0.846

Tabla 4. Métricas de los cuatro modelos evaluados sobre el conjunto de prueba (30%).




Figura 3. Matrices de confusión de los cuatro modelos sobre el conjunto de prueba.

5.3 Selección del mejor modelo

Se seleccionó el modelo con mejor F1, ya que en la clasificación de tweets de desastre ambos tipos de error importan: un falso negativo (no detectar un desastre real) puede significar perder una alerta relevante, mientras que un falso positivo (marcar como desastre algo que no lo es) satura de ruido un sistema de monitoreo. El F1 resume ese equilibrio en un solo número.

Los cuatro modelos quedan bastante parejos (F1 entre 0.739 y 0.764, todos con AUC alrededor de 0.84–0.86), lo cual sugiere que la representación de texto elegida (TF-IDF con unigramas y bigramas) captura información realmente útil, más allá del algoritmo específico que se use encima. Por F1, el mejor modelo es la Regresión Logística (0.764), aunque por muy poco margen sobre Naive Bayes (0.760).

- Naive Bayes es el más "cauteloso": tiene la precisión más alta (0.853) — cuando predice "desastre", casi siempre acierta — pero es el que más desastres reales deja pasar (el recall más bajo de los cuatro, 0.686).
- Regresión Logística logra el mejor equilibrio entre precisión (0.773) y recall (0.755), lo que la hace preferible cuando ambos tipos de error tienen costo similar, como en este caso.
- SVM Lineal y Random Forest quedan por debajo en F1 y AUC, sin ofrecer una ventaja clara sobre los dos anteriores.

Por estas razones, la Regresión Logística se utilizó como el "mejor modelo" en las secciones siguientes (función de clasificación e Inciso 10).

6. Función de clasificación de tweets nuevos

Se implementó la función `clasificar_tweet(texto)`, que recibe el texto crudo de un tweet (sin preprocesar) y aplica internamente los mismos pasos usados para entrenar: limpieza con `clean_text`, vectorización con el mismo `TfidfVectorizer` ya ajustado, y predicción con el mejor modelo (Regresión Logística). Así el usuario puede pasar un tweet tal como lo escribiría, sin preocuparse por el preprocesamiento.

La función se probó con cinco tweets de ejemplo, resumidos en la Tabla 5.

Tweet	Predicción	Probabilidad
Massive earthquake just hit the city, buildings are collapsing! #emergency	Desastre real	0.874
This new coffee shop is on fire, the espresso is	No es un desastre	0.208

Tweet	Predicción	Probabilidad
amazing!!		
Wildfire spreading fast near the highway, evacuate now	Desastre real	0.893
I'm dying of laughter watching this show lol	No es un desastre	0.219
Call 911, there's been a serious car accident on the freeway	Desastre real	0.779

Tabla 5. Resultados de la función clasificar_tweet sobre cinco tweets de prueba.

La función clasificó correctamente los cinco tweets, incluyendo dos casos que suelen ser difíciles para un clasificador de texto simple. "This new coffee shop is on fire..." se clasificó como no desastre (probabilidad 0.208) a pesar de contener la palabra "fire", lo que indica que el modelo no depende únicamente de palabras sueltas asociadas a desastres, sino que aprovecha el contexto capturado por los bigramas del TF-IDF (p. ej. "coffee shop", "espresso amazing"). Por su parte, "Call 911, there's been a serious car accident..." se clasificó correctamente como desastre real (probabilidad 0.779), lo que confirma que la decisión tomada en la Sección 2 de conservar el número 911 (en vez de eliminarlo junto con el resto de dígitos) sí aporta señal útil al modelo.

7. Clasificación de sentimiento (positivo, negativo, neutro)

7.1 Enfoque y decisión sobre los emoticones

Se utilizó un enfoque de léxico: un diccionario de palabras positivas y otro de negativas tomado del Opinion Lexicon de Hu y Liu, disponible a través de NLTK (`nltk.corpus.opinion_lexicon`), que contiene 2,006 palabras positivas y 4,783 negativas. A este léxico se agregó un pequeño diccionario propio de emoticones comunes (positivos: ":", ":-)", ":d", ";)", "<3", "xd", entre otros; negativos: ":(", ":-(", ":'(", ":/", ">:", entre otros).

Por cada tweet se cuentan cuántas palabras y emoticones positivos y negativos contiene; la diferencia entre ambos conteos (`sentimiento_score`) da el puntaje de sentimiento: positivo si predominan las palabras/emoticones positivos, negativo si predominan los negativos, y neutro en caso de empate (incluyendo cero coincidencias).

¿Vale la pena dejar los emoticones? Sí. A diferencia del preprocesamiento hecho para el modelo de clasificación de desastre (Sección 2), donde se descartaron por aparecer en pocos tweets y no ayudar a distinguir "desastre" de "no desastre", en el análisis de sentimiento un emoticono como ":" o "<3" es una señal directa y no ambigua de polaridad emocional, muchas veces más clara que las palabras del propio texto. Por eso

aquí se procesan por separado, buscándolos como subcadenas antes de tokenizar por palabras.

7.2 Distribución del sentimiento

Etiqueta	Cantidad	% del total
Negativo	3,592	47.2%
Neutro	2,920	38.4%
Positivo	1,101	14.5%

Tabla 6. Distribución de la etiqueta de sentimiento sobre el total de 7,613 tweets.




Figura 4. Distribución de sentimiento (positivo/neutro/negativo) por categoría (target).

target	Negativo	Neutro	Positivo
0 — No desastre	41.1%	39.7%	19.2%
1 — Desastre real	55.3%	36.5%	8.2%

Tabla 7. Distribución de sentimiento por categoría, en proporción dentro de cada clase.

7.3 Interpretación

En general, el sentimiento negativo domina en todo el dataset (3,592 tweets, 47.2%), seguido de neutro (2,920, 38.4%) y positivo bastante más atrás (1,101, 14.5%), algo esperable en un dataset centrado en catástrofes y emergencias, aun incluyendo los tweets que no describen un desastre real.

Comparando por categoría, sí se cumple lo esperado: los tweets de desastre real (target=1) son notablemente más negativos (55.3%) que los de no desastre (41.1%), y a la vez son los que menos sentimiento positivo tienen (8.2% contra 19.2% en no desastre). El neutro se mantiene similar en ambos grupos (36.5% vs. 39.7%), lo cual tiene sentido: muchos tweets son simplemente informativos ("14 personas fueron evacuadas") sin carga emocional explícita, sin importar si describen un desastre real o no.

8. Tweets más extremos y comparación de sentimiento por categoría

8.1 Los 10 tweets más negativos

Ordenando el dataset por sentimiento_score de menor a mayor, se obtuvieron los 10 tweets más negativos (Tabla 8). De estos, solo 3 pertenecen a la categoría de desastre real y 7 a la de no desastre.

#	Score	target	Tweet (extracto)
1	-13	0	"wreck? wreck wreck wreck wreck wreck wreck..."
2	-6	1	"Mad River Complex fires have burned 14028 acres, 8% contained..."
3	-6	1	"Bomb Crash Loot Riot Emergency Pipe Bomb Nuclear Chemical Spill Gas Ri..."
4	-6	0	"Honestly nightmarish. God driving to new places is always stressful..."
5	-6	0	"One Direction is taking a break after this next album. My heart has su..."
6	-5	0	"I reject the laws of the misguided false prophets, imprison nations..."
7	-5	1	"@binellithresa TY for the follow... BRUTALLY..."
8	-5	0	"@booksbyRoger TY for the follow... BRUTALLY..."
9	-5	0	"Politicians are using false allegations to attack #PlannedParenthood..."

#	Score	target	Tweet (extracto)
10	-5	0	"Is it possible to sneak into a hospital so I can stab myself with a ha..."

Tabla 8. Los 10 tweets con menor sentimiento_score (más negativos).

Esto ocurre porque los tweets de no desastre de esta lista usan lenguaje fuertemente negativo de forma personal o figurativa ("nightmarish", "reject", "stab"), mientras que los tweets de desastre real sí describen incidentes (incendios, bombas), pero con un estilo más informativo y objetivo que apenas alcanza puntajes cercanos a -6. El tweet más negativo de todo el dataset ("wreck? wreck wreck wreck...") es de no desastre, porque repite la palabra "wreck" en tono de burla y el léxico la cuenta como negativa en cada repetición, inflando artificialmente el puntaje.

8.2 Los 10 tweets más positivos

De forma simétrica, ordenando por sentimiento_score de mayor a menor se obtuvieron los 10 tweets más positivos (Tabla 9). Aquí la situación se invierte: 8 de los 10 son de la categoría de no desastre y solo 2 de desastre real.

#	Score	target	Tweet (extracto)
1	6	1	"@Raishimi33 :) well I think that sounds like a fine plan where little..."
2	4	1	"@flickershowell oh wow my heart collapsed cool im crying cool cool"
3	4	0	"@mattcohen4fake Gamma Ray, January, Worlds Collide, She Waits, Be Me, Wave..."
4	4	0	"@batfanuk we enjoyed the show today. Great fun. The emergency non evac..."
5	4	0	"@batfanuk we enjoyed the show today. Great fun. The emergency non evac..."
6	4	0	"@Morning_Joe @Reince @PressSec Joe ur so smart u should run 4 presiden..."
7	4	0	"Super sweet and beautiful :) https://t.co/... "
8	4	0	"Check out 'Want Twister Tickets AND A VIP EXPERIENCE To See SHANIA?..."
9	3	0	"Aftershock back to school kick off was great. I want to thank everyone..."
10	3	0	"A fun filled happy-hour at Simmons bar in Camden with this handsome on..."

Tabla 9. Los 10 tweets con mayor sentimiento_score (más positivos).

Los tweets más positivos hablan de planes agradables, shows, música o encuentros sociales, es decir, contenido cotidiano, y varios usan emoticonos como ":" o "<3", que suman directamente al puntaje. El resultado es coherente con la idea de que los tweets felices suelen ser ajenos a las emergencias, aunque hay excepciones, como el tweet de desastre con puntaje 6 que usa emoticonos positivos pese a estar en la categoría de desastre real.

8.3 ¿Son los tweets de desastre real más negativos que los de no desastre?

Para responder se compararon las medias y medianas del sentimiento_score en cada categoría (Tabla 10), se graficó la distribución con un boxplot (Figura 5) y se aplicaron la prueba t de Welch y la prueba de Mann-Whitney U (unilateral, con la hipótesis de que el score en desastre es menor que en no desastre).

Categoría	Media	Mediana	Desv. estándar	n
Desastre (target=1)	-0.797	-1.0	1.174	3,271
No desastre (target=0)	-0.344	0.0	1.162	4,342

Tabla 10. Estadísticos descriptivos de sentimiento_score por categoría.




Figura 5. Distribución de sentimiento_score por categoría (boxplot).

Sí, los tweets de desastre real son claramente más negativos que los de no desastre. La media del puntaje en desastre es -0.797, frente a -0.344 en no desastre, con mediana -1 en desastre y 0 en no desastre, lo que muestra que la distribución completa está desplazada hacia lo negativo en el grupo de desastre. La prueba t de Welch ($t = -16.759$, $p = 7.74 \times 10^{-62}$) y la prueba de Mann-Whitney U ($U = 5,620,210$, $p = 4.15 \times 10^{-60}$) rechazan la igualdad de las distribuciones con valores extremadamente pequeños, por lo que la diferencia es estadísticamente significativa y no se debe al azar. Este resultado es coherente con lo visto en la Sección 7.3, donde 55.3% de los tweets de desastre resultaron negativos.

9. La variable 'negatividad' y su impacto en el modelo de clasificación

9.1 Creación de la variable

Se definió negatividad como el conteo de palabras negativas más emoticones negativos de cada tweet ($\text{negatividad} = \text{palabras_negativas} + \text{emoticones_negativos}$), calculado a partir de las columnas obtenidas en el análisis de sentimiento del Inciso 8. La negatividad promedio es de 0.813 en tweets de no desastre y 1.030 en tweets de desastre, y su correlación con target es de 0.109.

9.2 Entrenamiento con la variable incluida

Usando el mismo split 70/30 y el mismo TF-IDF (unigramas + bigramas) de la Sección 5, se agregó negatividad como una columna numérica adicional a las matrices de entrenamiento y prueba (mediante `scipy.sparse.hstack`), pasando de 4,564 a 4,565 columnas. Se volvieron a entrenar los cuatro modelos con los mismos hiperparámetros; los resultados se comparan en la Tabla 11.

Modelo	F1 base	F1 con negatividad	Diferencia (Δ F1)
Naive Bayes	0.760	0.760	0.000
Regresión Logística	0.764	0.760	-0.005
SVM Lineal	0.746	0.746	+0.001
Random Forest	0.739	0.732	-0.008

Tabla 11. Comparación del F1 de cada modelo antes y después de incluir la variable negatividad.

9.3 Discusión

La inclusión de la variable de negatividad no mejoró los resultados del modelo de clasificación. En la Regresión Logística, el mejor modelo de la Sección 5, el F1 pasó de 0.764 a 0.760 (una diferencia de -0.005, dentro del margen de ruido), y los demás modelos quedaron prácticamente iguales o ligeramente peores (Random Forest bajó 0.008, SVM Lineal subió apenas 0.001). Ningún modelo mejoró de forma apreciable.

La razón principal es que negatividad es un resumen del conteo de palabras y emoticones negativos, información que el TF-IDF ya codifica de forma más rica como características individuales dentro de las 4,564 features de texto (por ejemplo, el modelo ya "ve" directamente palabras como killed o disaster, en vez de solo su conteo agregado). Además, la correlación de negatividad con target es baja (≈ 0.109), lo que confirma que por sí sola discrimina poco entre clases. En resumen, se trata de información redundante frente al vocabulario ya vectorizado, por lo que no aporta señal nueva al modelo.

10. Conclusiones

- La limpieza del texto (minúsculas, remoción de URLs/números/puntuación/stopwords, con la excepción deliberada del '911') resultó suficiente para obtener un vocabulario limpio y discriminante, sin necesidad de técnicas más complejas de normalización.
- El análisis de frecuencias y n-gramas mostró que las palabras temáticas específicas (disaster, suicide bomber, oil spill) discriminan mejor que las palabras genéricas, y que los bigramas/trigramas ayudan a resolver ambigüedades de palabras que aparecen en ambas clases (p. ej. burning buildings).
- De los cuatro modelos evaluados sobre TF-IDF (unigramas + bigramas), la Regresión Logística obtuvo el mejor F1 (0.764) con un balance razonable entre precisión y recall, aunque los cuatro modelos quedaron relativamente parejos, lo que indica que la representación del texto pesa más que el algoritmo elegido.
- El análisis de sentimiento basado en el léxico Opinion Lexicon (NLTK) confirmó que los tweets de desastre real son significativamente más negativos que los de no desastre (55.3% vs. 41.1% negativos; diferencia estadísticamente significativa según las pruebas t de Welch y Mann-Whitney U), aunque el sentimiento por sí solo no basta para separar perfectamente ambas clases, como lo muestran los 10 tweets más negativos y más positivos, dominados en ambos casos por tweets de no desastre con lenguaje coloquial o figurativo.

- Agregar una variable de negatividad derivada del análisis de sentimiento no mejoró el desempeño del clasificador, porque esa información ya está contenida, de forma más granular, en las características de TF-IDF.

11. Referencias y herramientas externas

- Hu, M. y Liu, B. (2004). Opinion Lexicon (positivo/negativo), utilizado a través de `nltk.corpus.opinion_lexicon` para el análisis de sentimiento del Inciso 8.
- NLTK — Natural Language Toolkit (<https://www.nltk.org/>), usado para el acceso al léxico de opiniones.
- scikit-learn (<https://scikit-learn.org/>) — `CountVectorizer`, `TfidfVectorizer`, y los modelos de clasificación (Naive Bayes, Regresión Logística, SVM Lineal, Random Forest).
- WordCloud para Python (https://github.com/amueller/word_cloud) — generación de las nubes de palabras de la Figura 2.
- SciPy (`scipy.stats`) — pruebas t de Welch y Mann-Whitney U del Inciso 9.3.
- Conjunto de datos: `train.csv` (Kaggle — "Natural Language Processing with Disaster Tweets"), 7,613 tweets etiquetados.