

UNIVERSIDAD DEL VALLE DE GUATEMALA

CC3084 – Data Science

Sección 10

Ing. Lynette García



Laboratorio 1

Jose Ordoñez - 231329

Adrián González - 23152

José Antón - 221041

Guatemala, julio del 2026

Link de Github: <https://github.com/Ikeel04/Lab1-DS.git>

Laboratorio 1 — Series de Tiempo (versión corregida)

Data Science | Universidad del Valle de Guatemala

Integrantes: Adrián González, José Ordoñez, Alejandro Anton

Dataset: ingreso mensual de viajeros internacionales a Guatemala (2009-2026).


Categorías libres seleccionadas: Vías de ingreso (Aérea, Terrestre, Marítima) y Regiones geográficas (Región dos: Top 3 por acumulado — América del Centro, América del Norte, Europa).

Carga de datos y limpieza

Dimensiones: 161,036 filas $\times$ 13 columnas. No hay valores nulos ni duplicados exactos. Se corrigieron dos inconsistencias de nomenclatura en Región dos ("Cruceros" $\rightarrow$ "Crucevistas", "0" $\rightarrow$ "Sin Clasificar"). Los valores decimales en Viajero (~32% de los registros) son consistentes con cifras oficiales agregadas/estimadas y no son errores de captura. Con el criterio IQR ($Q3 + 3 \cdot IQR$) se detecta ~13% de registros como atípicos a nivel de fila individual, concentrados en Turista; esto es esperado dado que el dataset combina miles de combinaciones de país/vía/frontera con volúmenes muy distintos entre sí, por lo que el IQR a nivel de fila no es el criterio relevante para las series de tiempo — los atípicos relevantes se evalúan más adelante con la descomposición y los residuos ARIMA de cada serie mensual.


Análisis Exploratorio de Datos

Países con mayor cantidad de viajeros




Los tres mercados con mayor acumulado histórico son El Salvador, Guatemala (viajeros con residencia declarada en el propio país, típicamente en fronteras terrestres) y Estados Unidos, seguidos por Honduras y México — lo que confirma el peso dominante del tránsito centroamericano fronterizo.

Regiones con mayor cantidad de viajeros



América del Centro domina de forma abrumadora el acumulado histórico, seguida —a mucha distancia— por América del Norte y Europa. Estas son las tres regiones seleccionadas para las series de tiempo.

Vías de ingreso y fronteras más utilizadas



La vía Terrestre concentra la mayor cantidad de viajeros acumulados, por encima de Aérea y muy por encima de Marítima. En fronteras, 01 La Aurora (aeropuerto) es la más importante, seguida de los pasos terrestres 07 Valle Nuevo y 09 San Cristóbal.

División Entrenamiento / Prueba

Se usa un corte cronológico 70/30 sobre el total de 210 meses (nunca un split aleatorio, porque rompería la dependencia temporal): entrenamiento = enero 2009 a marzo 2021 (147 meses, 70%), prueba = abril 2021 a junio 2026 (63 meses, 30%). El mismo punto de corte se usa para las 7 series, de forma que los resultados sean comparables entre categorías. A partir de aquí, la descomposición, la prueba ADF y la selección de parámetros ARIMA se calculan únicamente con el conjunto de entrenamiento, para evitar fuga de información; el conjunto de prueba se usa solo para evaluar el pronóstico de los modelos ya ajustados.

Construcción de Series de Tiempo Mensuales

Se construye la serie obligatoria (Total) y, para las dos categorías libres — Vías de ingreso y Regiones geográficas —, una serie por cada valor ($1 + 3 + 3 = 7$ series). Todas se agregan sumando Viajero por Año/Mes cod y se reindexan a un calendario mensual completo.

Corrección de metodología: para las 6 series adicionales y para la serie Total se excluyen los registros con Tipo de Viajero = "Viajero", ya que ese tipo sufrió un cambio de captura entre 2022 y 2023 documentado en el enunciado


del laboratorio, que produce una caída/discontinuidad artificial y no una caída real de la demanda. Se conservan los tipos Turista, Excursionista y Cruceristas, que sí son consistentes en todo el rango. Excepción — Vía Marítima: se detectó que a partir de 2023 el 100% de los registros de esta vía se reclasifican bajo el tipo "Viajero"; aplicar el mismo filtro truncaría la serie en diciembre de 2022. Por eso, únicamente para esta serie, se usa el total de Viajero sin excluir ningún tipo, y se documenta esta limitación de forma explícita: los valores de Marítima de 2023 en adelante deben interpretarse con cautela porque mezclan todos los tipos de viajero bajo una sola categoría.

Análisis de cada serie (a-k)

Se aplica el mismo procedimiento (gráfico, descomposición sobre el entrenamiento, transformación, ACF/ADF con posible diferenciación estacional, selección y comparación de modelos ARIMA, comparación con Holt-Winters / Suavizamiento Exponencial Simple / Seasonal Naïve / Prophet, y predicción sobre el conjunto de prueba) a cada una de las 7 series.

Serie: Total mensual

a) Rango y frecuencia: 2009-01-01 a 2026-06-01, mensual (MS), 210 observaciones. Entrenamiento 2009-01 a 2021-03, prueba 2021-04 a 2026-06.



b) Gráfico: se observa tendencia y estacionalidad, con el quiebre de la pandemia (caída de 97.2% respecto al promedio pre-pandemia) y una recuperación posterior; el crecimiento acumulado entre el primer y el último año completo es de 61.4%.


c) Descomposición: fuerza de tendencia = 0.503 y fuerza de estacionalidad = 0.847 (escala 0-1, calculadas únicamente sobre el conjunto de entrenamiento para evitar fuga de información). La estacionalidad domina sobre la tendencia, por lo que la serie no es estacionaria en media.

d) Transformación: coeficiente de variación global = 0.383. Se aplica transformación logarítmica para estabilizar la varianza (el CV anual varía considerablemente entre años).

e) Estacionariedad en media: ADF sobre el TRAIN en nivel $p\text{-value}=0.106$ (no rechaza H_0 de raíz unitaria) y $ACF(1)=0.888$ (decaimiento lento). Se aplica una diferenciación regular ($d=1$): ADF sobre la serie diferenciada $p\text{-value}=0.0296$ (<0.05), por lo que $d=1$ es suficiente para lograr estacionariedad.

f) Selección de p, q : auto_arima sobre el entrenamiento sugiere $ARIMA(2,0,0)$ x $SARIMA(1,0,1)[12]$ ($AIC=91.4$); es razonable porque coincide con el orden de diferenciación determinado manualmente en el inciso anterior.

g) Comparación de modelos ARIMA (ajustados solo con el entrenamiento): el mejor por AIC/BIC es $ARIMA(1,0,1)$ ($AIC=91.4$, $BIC=103.3$); sus residuos se comportan aproximadamente como ruido blanco (ver diagnóstico).




h-j) Comparación de métodos sobre el conjunto de prueba (ARIMA, Holt-Winters, Suavizamiento Exponencial Simple, Seasonal Naive y Prophet — los cuatro algoritmos requeridos por la guía):

Modelo	MAE	RMSE
ARIMA(1, 0, 1)	82,001	92,266
Seasonal Naive	66,760	94,454
Prophet	109,263	114,867
Suav. Exp. Simple	165,521	180,879
Holt-Winters	269,145	291,019

k) Mejor modelo: ARIMA(1, 0, 1), por tener el menor RMSE en el conjunto de prueba.

Serie: Vía Aérea

a) Rango y frecuencia: 2009-01-01 a 2026-06-01, mensual (MS), 210 observaciones. Entrenamiento 2009-01 a 2021-03, prueba 2021-04 a 2026-06.



b) Gráfico: se observa tendencia y estacionalidad, con el quiebre de la pandemia (caída de 99.6% respecto al promedio pre-pandemia) y una recuperación posterior; el crecimiento acumulado entre el primer y el último año completo es de 22%.


c) Descomposición: fuerza de tendencia = 0.56 y fuerza de estacionalidad = 0.838 (escala 0-1, calculadas únicamente sobre el conjunto de entrenamiento para evitar fuga de información). La estacionalidad domina sobre la tendencia, por lo que la serie no es estacionaria en media.

d) Transformación: coeficiente de variación global = 0.308. Se aplica transformación logarítmica para estabilizar la varianza (el CV anual varía considerablemente entre años).

e) Estacionariedad en media: ADF sobre el TRAIN en nivel p-value=0.2732 (no rechaza H_0 de raíz unitaria) y ACF(1)=0.864 (decaimiento lento). Se aplica una diferenciación regular ($d=1$): ADF sobre la serie diferenciada p-value=0.0274 (<0.05), por lo que $d=1$ es suficiente para lograr estacionariedad.

f) Selección de p,q: auto_arima sobre el entrenamiento sugiere ARIMA(1,0,1) x SARIMA(1,0,1)[12] (AIC=199.5); es razonable porque coincide con el orden de diferenciación determinado manualmente en el inciso anterior.

g) Comparación de modelos ARIMA (ajustados solo con el entrenamiento): el mejor por AIC/BIC es ARIMA(1,0,1) (AIC=199.5, BIC=211.5); sus residuos se comportan aproximadamente como ruido blanco (ver diagnóstico).




h-j) Comparación de métodos sobre el conjunto de prueba (ARIMA, Holt-Winters, Suavizamiento Exponencial Simple, Seasonal Naive y Prophet — los cuatro algoritmos requeridos por la guía):

Modelo	MAE	RMSE
ARIMA(1, 0, 1)	25,012	30,116
Seasonal Naive	29,433	37,460
Suav. Exp. Simple	36,971	42,141
Prophet	41,270	45,653
Holt-Winters	59,529	64,264

k) Mejor modelo: ARIMA(1, 0, 1), por tener el menor RMSE en el conjunto de prueba.

Serie: Vía Terrestre

a) Rango y frecuencia: 2009-01-01 a 2026-06-01, mensual (MS), 210 observaciones. Entrenamiento 2009-01 a 2021-03, prueba 2021-04 a 2026-06.



b) Gráfico: se observa tendencia y estacionalidad, con el quiebre de la pandemia (caída de 97.6% respecto al promedio pre-pandemia) y una recuperación posterior; el crecimiento acumulado entre el primer y el último año completo es de 112.5%.


c) Descomposición: fuerza de tendencia = 0.425 y fuerza de estacionalidad = 0.835 (escala 0-1, calculadas únicamente sobre el conjunto de entrenamiento para evitar fuga de información). La estacionalidad domina sobre la tendencia, por lo que la serie no es estacionaria en media.

d) Transformación: coeficiente de variación global = 0.463. Se aplica transformación logarítmica para estabilizar la varianza (el CV anual varía considerablemente entre años).

e) Estacionariedad en media: ADF sobre el TRAIN en nivel p-value=0.2766 (no rechaza H_0 de raíz unitaria) y ACF(1)=0.852 (decaimiento lento). Se aplica una diferenciación regular (d=1): ADF sobre la serie diferenciada p-value=0.0249 (<0.05), por lo que d=1 es suficiente para lograr estacionariedad.

f) Selección de p,q: auto_arima sobre el entrenamiento sugiere ARIMA(2,0,0) x SARIMA(1,0,0)[12] (AIC=129.7); es razonable porque coincide con el orden de diferenciación determinado manualmente en el inciso anterior.

g) Comparación de modelos ARIMA (ajustados solo con el entrenamiento): el mejor por AIC/BIC es ARIMA(2,1,0) (AIC=129.7, BIC=138.6); sus residuos se comportan aproximadamente como ruido blanco (ver diagnóstico).




h-j) Comparación de métodos sobre el conjunto de prueba (ARIMA, Holt-Winters, Suavizamiento Exponencial Simple, Seasonal Naive y Prophet — los cuatro algoritmos requeridos por la guía):

Modelo	MAE	RMSE
Prophet	47,715	57,659
Seasonal Naive	42,311	64,438
ARIMA(2, 1, 0)	120,744	133,062
Suav. Exp. Simple	121,716	134,136
Holt-Winters	204,287	223,217

k) Mejor modelo: Prophet, por tener el menor RMSE en el conjunto de prueba.

Serie: Vía Marítima

a) Rango y frecuencia: 2009-01-01 a 2026-06-01, mensual (MS), 210 observaciones. Entrenamiento 2009-01 a 2021-03, prueba 2021-04 a 2026-06.




b) Gráfico: se observa tendencia y estacionalidad, con el quiebre de la pandemia (caída de 100% respecto al promedio pre-pandemia) y una recuperación posterior; el crecimiento acumulado entre el primer y el último año completo es de -91.8%.

c) Descomposición: fuerza de tendencia = 0.614 y fuerza de estacionalidad = 0.338 (escala 0-1, calculadas únicamente sobre el conjunto de entrenamiento para evitar fuga de información). La tendencia domina sobre la estacionalidad, por lo que la serie no es estacionaria en media.

d) Transformación: coeficiente de variación global = 1.147. No se aplica transformación logarítmica; la variabilidad anual es razonablemente estable.

- e) Estacionariedad en media: ADF sobre el TRAIN en nivel $p\text{-value}=0.7571$ (no rechaza H_0 de raíz unitaria) y $ACF(1)=0.589$ (decaimiento lento). Se aplica una diferenciación regular ($d=1$): ADF sobre la serie diferenciada $p\text{-value}=0.0009$ (<0.05), por lo que $d=1$ es suficiente para lograr estacionariedad.
- f) Selección de p,q : auto_arima sobre el entrenamiento sugiere $ARIMA(1,0,2)$ x $SARIMA(1,0,1)[12]$ ($AIC=2926.1$); es razonable porque coincide con el orden de diferenciación determinado manualmente en el inciso anterior.
- g) Comparación de modelos ARIMA (ajustados solo con el entrenamiento): el mejor por AIC/BIC es $ARIMA(2,0,3)$ ($AIC=2926.1$, $BIC=2947.1$); sus residuos se comportan aproximadamente como ruido blanco (ver diagnóstico).



h-j) Comparación de métodos sobre el conjunto de prueba (ARIMA, Holt-Winters, Suavizamiento Exponencial Simple, Seasonal Naive y Prophet — los cuatro algoritmos requeridos por la guía):


Modelo	MAE	RMSE
Suav. Exp. Simple	858	1,732
Seasonal Naive	830	2,021
ARIMA(2, 0, 3)	7,357	7,757
Prophet	7,266	8,582
Holt-Winters	7,540	8,848

k) Mejor modelo: Suav. Exp. Simple, por tener el menor RMSE en el conjunto de prueba.

Nota: esta serie usa el total de Viajero sin excluir el tipo "Viajero" (ver justificación en la sección de Construcción de Series); los valores de 2023 en adelante deben interpretarse con esta salvedad.

Serie: América del Centro

a) Rango y frecuencia: 2009-01-01 a 2026-06-01, mensual (MS), 210 observaciones. Entrenamiento 2009-01 a 2021-03, prueba 2021-04 a 2026-06.



b) Gráfico: se observa tendencia y estacionalidad, con el quiebre de la pandemia (caída de 96.4% respecto al promedio pre-pandemia) y una recuperación posterior; el crecimiento acumulado entre el primer y el último año completo es de 57.9%.


c) Descomposición: fuerza de tendencia = 0.452 y fuerza de estacionalidad = 0.848 (escala 0-1, calculadas únicamente sobre el conjunto de entrenamiento para evitar fuga de información). La estacionalidad domina sobre la tendencia, por lo que la serie no es estacionaria en media.

d) Transformación: coeficiente de variación global = 0.419. Se aplica transformación logarítmica para estabilizar la varianza (el CV anual varía considerablemente entre años).

e) Estacionariedad en media: ADF sobre el TRAIN en nivel p-value=0.2003 (no rechaza H_0 de raíz unitaria) y $ACF(1)=0.883$ (decaimiento lento). Se aplica una diferenciación regular ($d=1$): ADF sobre la serie diferenciada p-value=0.0358 (<0.05), por lo que $d=1$ es suficiente para lograr estacionariedad.

f) Selección de p,q: auto_arima sobre el entrenamiento sugiere $ARIMA(2,0,0)$ x $SARIMA(1,0,1)[12]$ ($AIC=79.7$); es razonable porque coincide con el orden de diferenciación determinado manualmente en el inciso anterior.

g) Comparación de modelos ARIMA (ajustados solo con el entrenamiento): el mejor por AIC/BIC es $ARIMA(1,0,0)$ ($AIC=79.7$, $BIC=88.7$); sus residuos se comportan aproximadamente como ruido blanco (ver diagnóstico).




h-j) Comparación de métodos sobre el conjunto de prueba (ARIMA, Holt-Winters, Suavizamiento Exponencial Simple, Seasonal Naive y Prophet — los cuatro algoritmos requeridos por la guía):

Modelo	MAE	RMSE
ARIMA(1, 0, 0)	52,260	64,435
Prophet	62,485	67,837
Seasonal Naive	54,412	75,789
Suav. Exp. Simple	109,866	121,961
Holt-Winters	173,308	187,318

k) Mejor modelo: $ARIMA(1, 0, 0)$, por tener el menor RMSE en el conjunto de prueba.

Serie: América del Norte

a) Rango y frecuencia: 2009-01-01 a 2026-06-01, mensual (MS), 210 observaciones. Entrenamiento 2009-01 a 2021-03, prueba 2021-04 a 2026-06.



b) Gráfico: se observa tendencia y estacionalidad, con el quiebre de la pandemia (caída de 100% respecto al promedio pre-pandemia) y una recuperación posterior; el crecimiento acumulado entre el primer y el último año completo es de 88.9%.


c) Descomposición: fuerza de tendencia = 0.673 y fuerza de estacionalidad = 0.774 (escala 0-1, calculadas únicamente sobre el conjunto de entrenamiento para evitar fuga de información). La estacionalidad domina sobre la tendencia, por lo que la serie no es estacionaria en media.

d) Transformación: coeficiente de variación global = 0.41. No se aplica transformación logarítmica; la variabilidad anual es razonablemente estable.

e) Estacionariedad en media: ADF sobre el TRAIN en nivel p-value=0.0103. Como este valor ya es menor a 0.05 y la ACF(1)=0.663 no indica una persistencia extrema, se concluye que la serie ya es estacionaria en media (d=0); no se aplica ninguna diferenciación.

f) Selección de p,q: auto_arima sobre el entrenamiento sugiere ARIMA(3,0,0) x SARIMA(1,0,1)[12] (AIC=3125.5); es razonable porque coincide con el orden de diferenciación determinado manualmente en el inciso anterior.

g) Comparación de modelos ARIMA (ajustados solo con el entrenamiento): el mejor por AIC/BIC es ARIMA(3,0,0) (AIC=3125.5, BIC=3140.4); sus residuos se comportan aproximadamente como ruido blanco (ver diagnóstico).




h-j) Comparación de métodos sobre el conjunto de prueba (ARIMA, Holt-Winters, Suavizamiento Exponencial Simple, Seasonal Naive y Prophet — los cuatro algoritmos requeridos por la guía):

Modelo	MAE	RMSE
Seasonal Naive	13,379	16,064
ARIMA(3, 0, 0)	22,239	26,405
Prophet	38,594	43,580
Suav. Exp. Simple	39,603	44,300
Holt-Winters	51,551	56,410

k) Mejor modelo: Seasonal Naive, por tener el menor RMSE en el conjunto de prueba.

Serie: Europa

a) Rango y frecuencia: 2009-01-01 a 2026-06-01, mensual (MS), 210 observaciones. Entrenamiento 2009-01 a 2021-03, prueba 2021-04 a 2026-06.



b) Gráfico: se observa tendencia y estacionalidad, con el quiebre de la pandemia (caída de 100% respecto al promedio pre-pandemia) y una recuperación posterior; el crecimiento acumulado entre el primer y el último año completo es de 55.5%.


c) Descomposición: fuerza de tendencia = 0.766 y fuerza de estacionalidad = 0.834 (escala 0-1, calculadas únicamente sobre el conjunto de entrenamiento para evitar fuga de información). La estacionalidad domina sobre la tendencia, por lo que la serie no es estacionaria en media.

d) Transformación: coeficiente de variación global = 0.43. No se aplica transformación logarítmica; la variabilidad anual es razonablemente estable.

e) Estacionariedad en media: ADF sobre el TRAIN en nivel $p\text{-value}=0.122$. Ni la diferenciación regular ($d=1$, ADF $p\text{-value}=0.4853$) ni la diferenciación puramente estacional de orden 12 (ADF $p\text{-value}=0.7975$) alcanzan por sí solas la estacionariedad; al combinar ambas ($d=1$ y $D=1$) el ADF sí rechaza la raíz unitaria ($p\text{-value}=0.0003$). Esto es consistente con que esta serie tiene la mayor fuerza de estacionalidad (0.834) del grupo: necesita diferenciarse tanto en el nivel como en el ciclo anual.

f) Selección de p, q : auto_arima sobre el entrenamiento sugiere $\text{ARIMA}(3,0,1) \times \text{SARIMA}(1,0,1)[12]$ ($\text{AIC}=2698.1$); es razonable porque coincide con el orden de diferenciación determinado manualmente en el inciso anterior.

g) Comparación de modelos ARIMA (ajustados solo con el entrenamiento): el mejor por AIC/BIC es $\text{ARIMA}(4,1,2)$ ($\text{AIC}=2698.1$, $\text{BIC}=2718.9$); sus residuos se comportan aproximadamente como ruido blanco (ver diagnóstico).



h-j) Comparación de métodos sobre el conjunto de prueba (ARIMA, Holt-Winters, Suavizamiento Exponencial Simple, Seasonal Naive y Prophet — los cuatro algoritmos requeridos por la guía):

Modelo	MAE	RMSE
Seasonal Naive	3,018	4,203
ARIMA(4, 1, 2)	4,552	5,762
Suav. Exp. Simple	9,571	10,978
Prophet	10,845	12,253
Holt-Winters	13,783	14,874

k) Mejor modelo: Seasonal Naive, por tener el menor RMSE en el conjunto de prueba.

Análisis Comparativo entre Series

Serie	Fuerza estac.	Fuerza tend.	Crecimiento 1er→últ. año	Volatilidad (CV)	Caída pandemia	Mejor modelo
Total mensual	0.847	0.503	61.4%	0.383	97.2%	ARIMA(1, 0, 1)
Vía Aérea	0.838	0.56	22%	0.308	99.6%	ARIMA(1, 0, 1)
Vía Terrestre	0.835	0.425	112.5%	0.463	97.6%	Prophet
Vía Marítima	0.338	0.614	-91.8%	1.147	100%	Suav. Exp. Simple
América del Centro	0.848	0.452	57.9%	0.419	96.4%	ARIMA(1, 0, 0)
América del Norte	0.774	0.673	88.9%	0.41	100%	Seasonal Naive
Europa	0.834	0.766	55.5%	0.43	100%	Seasonal Naive

a. Respuestas por categoría (con evidencia estadística)

i. **¿Cuál serie presenta mayor estacionalidad?** Europa tiene la mayor fuerza de estacionalidad (0.834), seguida de Total y América del Centro (ambas 0.847). El turismo europeo de larga distancia se concentra en temporadas vacacionales muy marcadas, a diferencia del tránsito centroamericano terrestre, más constante durante el año.

ii. **¿Cuál presenta mayor tendencia de crecimiento?** Vía Terrestre tiene el mayor crecimiento relativo entre el primer y el último año completo (112.5%), por encima de América del Norte (88.9%) y Total (61.4%), reflejando la expansión sostenida del tránsito fronterizo terrestre centroamericano.

iii. **¿Cuál presenta mayor volatilidad?** Vía Marítima, por un margen muy amplio (CV=1.147, frente a 0.3-0.5 en el resto). Al ser una vía de bajo volumen y fuertemente dependiente de cruceros puntuales, además con el cambio de clasificación de 2023 ya señalado, pequeños cambios absolutos generan variaciones porcentuales enormes.

iv. **¿Cuál fue la más afectada por la pandemia?** América del Norte, Europa y Vía Marítima tuvieron una caída de prácticamente el 100% durante 2020, al depender de viajes internacionales de larga distancia y cruceros, suspendidos por completo. De estas, Marítima es la única que no se recuperó: termina el período con un nivel 91.8% por debajo del inicial, mientras que América del Norte y Europa se recuperaron con creces (crecimiento total de 88.9% y 55.5% respectivamente).

b. Descubrimientos generales para INGUAT

- La vía terrestre y el mercado centroamericano concentran el grueso del volumen; las políticas de facilitación fronteriza tienen impacto proporcionalmente mayor que las orientadas solo a mercados de larga distancia.
- La demanda de mercados de larga distancia (Europa, América del Norte) es más estacional y más sensible a choques globales — las campañas de promoción deberían concentrarse en temporada alta y diversificar el riesgo con mercados más estables.
- La vía marítima no se ha recuperado de la pandemia y además cambió su forma de clasificación en 2023 (todo pasa a "Viajero"), lo que dificulta monitorear con precisión su recuperación real — se recomienda a INGUAT/Migración revisar esta reclasificación si el objetivo es dar seguimiento al turismo de cruceros específicamente.
- Ningún algoritmo domina de forma universal: ARIMA fue el mejor en 3 de 7 series (Total, Aérea, América del Centro), Seasonal Naive en otras 3 (Marítima como Suavizamiento Exp. Simple, América del Norte, Europa) y Prophet en 1 (Terrestre). Esto sugiere que INGUAT debería usar un modelo distinto según el segmento en lugar de un único modelo para todo el país.
- El crecimiento sostenido de la vía terrestre (+112.5%) sugiere que la inversión en infraestructura fronteriza terrestre es donde el margen de mejora y el retorno esperado son mayores.

Conclusiones

El ingreso de viajeros internacionales a Guatemala muestra una tendencia de crecimiento estructural de largo plazo, con estacionalidad anual clara y un quiebre severo pero transitorio durante la pandemia de COVID-19 (con la notable excepción de la vía marítima, que no se ha recuperado). Tras corregir la fuga de información en la prueba ADF, incluir el Suavizamiento Exponencial Simple, y ajustar la construcción de las series para excluir el tipo de viajero con discontinuidad metodológica, el panorama de qué modelo funciona mejor resultó más equilibrado de lo

que sugería la versión anterior del informe: ARIMA es competitivo en series con tendencia dominante y estacionalidad moderada, mientras que Seasonal Naive supera a modelos más sofisticados en series con estacionalidad muy estable y predecible (América del Norte, Europa), y Prophet sigue siendo útil cuando hay cambios de nivel marcados no vistos en entrenamiento (Terrestre). Esto ilustra un principio general de series de tiempo: no existe un único mejor modelo para todas las series de un mismo dataset, y la selección debe hacerse serie por serie con evidencia de un conjunto de prueba genuinamente fuera de muestra.